

研報智慧檢索系統

把散落在資料夾裡的 1.5 萬份券商研究報告 (PDF / DOCX)，變成一個能用自然語言提問、按市場與標的篩選、一鍵閱讀原文的智慧檢索庫。

文件日期：2026 年 6 月 10 日

15,866

原始研報檔案

15,445

去重後候選研報

5 維

AI 自動標籤

1024 維

語意向量檢索

過去要在上萬份研報中找特定主題，只能靠檔名猜測與逐份翻閱。本系統把全文抽取、AI 判讀分類、語意向量化串成全自動管線，以網頁提供全辦公室使用——查資料從數小時縮短到數秒。

處理管線總覽 Pipeline Overview

研報自動匯入/ 資料夾 — 15,866 份券商研報原始檔 (PDF / DOCX)

1 文字抽取 `extract_all.py`

多進程平行抽取全文 + 檔名解析 (券商、日期、股號)；以檔案內容雜湊 (`file_hash`) 去重，自動排除行政文件與無文字層的掃描檔。

15,445 篇候選研報 (全文 JSONL)

2 AI 標籤分類 `tag_all_cli.py` × Claude

每篇報告交給 Claude AI 判讀檔名 + 內文，輸出五維結構化標籤：市場、商品類型、個股 / 期貨關聯、具體標的代碼，並判斷「是否真的是研報」當守門員。

每篇一個標籤 JSON (可續傳、可稽核)

3 向量化導入 `ingest_all.py` × BGE-M3

全文切成約 600 字的語意塊 (段落優先、80 字重疊)，每塊以 BGE-M3 模型轉成 1024 維向量，連同全文與標籤寫入 PostgreSQL (`pgvector` + HNSW 索引)。

研報資料庫：報告 metadata + 全文 + 語意向量

4 語意檢索網頁 `FastAPI` + `pgvector`

輸入問題 → 即時轉向量 → 找出語意最接近的報告片段，按報告分組呈現；支援瀏覽全部、市場 / 商品 / 標的篩選、內嵌 PDF 原文閱讀。辦公室同仁經區網直接使用。

各階段詳解 Stage Details

① 文字抽取——以多進程平行處理上萬份檔案，約一小時完成全量。每個檔案以內容雜湊 (file_hash) 作為全管線的唯一身分證：重複檔案自動去重、後續每一階段都以它作為續傳與比對的鍵。抽取同時從檔名解析出來源券商、報告日期、股票代號等 metadata，行政文件 (對帳單、通知書) 與掃描檔在此階段即被排除。

② AI 標籤分類——一萬五千篇報告靠人工分類並不可行。系統將每篇報告的檔名與內文摘錄交給 Claude AI 判讀，輸出下表的結構化標籤。並行多工處理，每小時可分類約 1,600 篇；失敗自動重試並記錄，重跑時自動跳過已完成者。

標籤維度	內容
市場	台股、美股、港股、陸股、外匯、台指期、總經、全球、加密貨幣——九選一
商品類型	股票、指數、期貨、選擇權、ETF、債券、外匯、原物料、加密 (可複選)
標的關聯	是否涉及個股 / 是否涉及期貨 (布林值，供快速篩選)
具體標的	個股代碼清單 (如 2330、2454)、期貨商品名清單 (如台指期、電子期)
守門判斷	is_research：是否為真正的研究報告 (行銷文宣、純數據表會被擋下) + 信心分數

標籤品質經過驗證：樣本批次 74 篇由人工全量稽核，零錯標，含多個邊界案例 (如「個股報告但提及期貨避險」) 皆判讀正確。

③ 向量化導入——通過守門的報告全文切成約 600 字的語意塊，切點優先落在段落邊界、相鄰塊保留 80 字重疊，避免關鍵語意被攔腰切斷。每塊文字經 BGE-M3 嵌入模型轉成 1024 維語意向量，寫入 PostgreSQL；向量欄位建 HNSW 索引，使「在數十萬向量中找最近鄰」能在毫秒級完成。每導入一篇、網頁立即可搜尋到一篇，不需等待全量完成。

④ 語意檢索網頁——後端常駐嵌入模型，查詢流程為：使用者的問題 → 轉成查詢向量 → pgvector 以餘弦相似度找出最接近的內文片段 → 按報告分組、依相關度排序呈現卡片。

網頁功能	說明
語意搜尋	輸入自然語言問題，顯示相關報告與命中片段 (含相關度分數、關鍵詞標亮)
預設瀏覽模式	不輸入關鍵字即列出全部已導入報告，依日期新到舊，分頁載入
三組篩選器	市場 (含各分類數量)、商品類型、個股 / 期貨——搜尋與瀏覽模式皆適用
查看完整報告	點擊卡片按鈕，原始 PDF 直接內嵌於彈窗中閱讀，亦可下載
區網共享	同仁瀏覽器開啟 http://192.168.1.128:8097 即可使用，無需安裝任何軟體

設計亮點 Design Highlights

語意搜尋，而非關鍵字搜尋

問「AI 伺服器散熱需求」能找到談「液冷、均熱片、3D VC」的報告——即使全文從未出現你輸入的字眼。向量檢索比對的是「意思」，不是字面。

全管線可中斷、可續傳

每階段都以 `file_hash` 為鍵、失敗有日誌；中斷後重跑自動跳過已完成部分。實際運轉中曾兩次遇到 AI 額度限制，皆於額度恢復後無痛續跑，已完成的工作零損失。

AI 當分類員，人類只做抽查

1.5 萬篇人工分類約需數百小時；AI 逐篇判讀僅需數小時，搭配樣本人工稽核（74 篇零錯標）確保品質。守門維度同時把非研報雜訊擋在資料庫之外。

增量上線，邊處理邊可用

標籤與導入皆為逐篇完成、逐篇生效——系統不需「全部跑完」才能使用，網頁上的報告數量每小時持續增長。

技術架構 Tech Stack

層面	技術選擇
文件解析	Python 多進程管線（PDF / DOCX 全文抽取 + 檔名 metadata 解析）
AI 分類	Claude（Haiku 模型），結構化 JSON 輸出，多執行緒並行 + 自動重試
嵌入模型	BGE-M3（多語言、1024 維 dense 向量），本機 CPU 運算、模型常駐記憶體
資料庫	PostgreSQL 16 + pgvector 擴充，HNSW 向量索引（Docker 容器）
後端 API	FastAPI（非同步），檢索 / 瀏覽 / 統計 / 原文服務端點
前端	單頁網頁（原生 JS），卡片式結果、即時篩選、PDF 內嵌彈窗
部署	WSL2 + Docker；經連接埠轉發與防火牆設定開放辦公室區網存取

目前進度 Status — 2026.06.10

階段	狀態	數量
① 文字抽取	✓ 全量完成	15,445 篇候選
② AI 標籤	進行中（52.5%）	8,113 篇完成，其中 7,408 篇確認為研報
③ 向量導入	背景執行中	已入庫持續增長
④ 檢索網頁	✓ 已上線	區網開放使用中

標籤與導入完成後，全庫約 7,400+ 篇可檢索研報；後續可擴充 GPU 加速、新報告自動入庫與 AI 摘要。